

Аналитический отчет.

Я попробовал применить классические методы машинного обучения к набору соединений с известными IC50, CC50 и индексом селективности SI. Моей задачей было по молекулярным дескрипторам либо предсказывать числовые значения (регрессия), либо делить соединения по порогам (классификация). Из моделей брал логистическую и линейную регрессию, случайный лес и градиентный бустинг. Метрики — RMSE, ROC-AUC, Accuracy и F1.

Для таргетов посчитал логарифмы ($\log_{10_IC50}$, $\log_{10_CC50}$ и $\log_{10_SI}$), так как распределения были сильно скошены. Признаки отмасштабировал через StandardScaler, выборки разбивал со стратификацией, чтобы не портить баланс классов.

В регрессии для IC50 и CC50 ансамбли (случайный лес и бустинг) дали RMSE на тесте заметно ниже, чем линейная регрессия. Это ожидаемо: связь дескрипторов с активностью/токсичностью нелинейная, линейная модель ее не ловит. А вот с SI сложнее - ошибки выше и разрыв между ансамблями и линейной моделью меньше, так как SI считается из двух величин, зависимость сложнее.

Для задач классификации по медиане IC50 и CC50 были обучены LogisticRegression, RandomForestClassifier и GradientBoostingClassifier. Для IC50 и CC50 случайный лес и бустинг выдали ROC-AUC в районе 0,83-0,85, F1 - около 0,7-0,75. Значит, по этим дескрипторам можно более-менее уверенно отличать соединения с IC50/CC50 выше медианы. Для предварительного отбора кандидатов такие модели уже могут быть полезны. С SI по медиане вышло не так хорошо. Все модели дали ROC-AUC только 0,65-0,67, F1 – 0,61-0,62. Классы сильно пересекаются, четкой границы в пространстве признаков нет. Но когда я взял порог не медиану, а фиксированное значение $SI > 8$, картина поменялась: у случайного леса ROC-AUC подскочил до 0,77, F1 до 0,73. Так что для селективности имеет смысл смотреть не формальное деление пополам, а именно выделять соединения с реально высокой селективностью.

Отдельно посмотрел важность признаков. Для IC50 и CC50 в топ-20 стабильно лезли дескрипторы, связанные с донорно-акцепторными группами (NHOHCount, NumHDonors), насыщенными гетероциклами, разными VSA и EState, а также частичными зарядами (MinPartialCharge и др.). Похоже, распределение заряда и полярные фрагменты действительно важны для активности и цитотоксичности. Для SI (особенно для $SI > 8$), важность сместилась в сторону других структурных мотивов: амидные и эпоксидные фрагменты, морфолиновое кольцо, количество насыщенных колец, BCUT2D, VSA_EState, плотность отпечатков (FpDensityMorgan). Причем топовые признаки совпадают у логистической регрессии, случайного леса и бустинга - значит, это не случайность. Химически это выглядит так: селективность определяется

балансом полярных фрагментов, насыщенностью скелета и общей формой молекулы, а не только отдельными группами.

Размер выборки относительно небольшой, поэтому полученные модели могут переобучаться на конкретный набор соединений и менять качество при добавлении новых данных. Для подбора гиперпараметров применялся GridSearchCV, но итоговая оценка качества в основном делалась на одном разбиении трейн/тест, использование более тщательной кросс-валидации и повторных разбиений могло бы сделать выводы более устойчивыми.

Несмотря на это, классические методы машинного обучения уже позволяют получать осмысленные результаты на химических данных. Для IC50 и CC50 удалось построить модели с хорошим качеством классификации по медиане, а для селективности SI - подобрать порог ($SI > 8$), при котором задача разделения на классы становится решаемой. Анализ важности признаков даёт понятные химико-биологические интерпретации, указывая на роль определённых типов фрагментов и распределения заряда в формировании активности, цитотоксичности и селективности. Я считаю, что работа показала, что даже относительно простые модели и базовые дескрипторы позволяют получить полезные выводы о влиянии структуры соединений на IC50, CC50 и SI и могут служить отправной точкой для более глубоких исследований и разработки практических предсказательных моделей. В дальнейшем было бы интересно расширить работу в нескольких направлениях. Во первых, можно увеличить объем данных и проверить, сохраняются ли выявленные закономерности на более крупных наборах соединений. Во вторых, имеет смысл попробовать более продвинутые алгоритмы (XGBoost, CatBoost), сравнить их с уже реализованными моделями и посмотреть, насколько они улучшают качество. В третьих, можно провести более детальный анализ признаков: отобрать оптимальный поднабор дескрипторов, добавить новые. Для индекса селективности стоит протестировать разные пороги (например, 5 и 10) и оценить, при каком варианте разделения модели дают наиболее устойчивые и интерпретируемые результаты.